

Eine Clusteranalyse deutscher Großstädte basierend auf Urbanität und Elektromobilität

Jakob Wenzel

Abstract—Die vorliegende Arbeit untersucht die Klassifizierung deutscher Großstädte im Spannungsfeld von Urbanität und Elektromobilität. Vor dem Hintergrund der notwendigen Transformation des Verkehrssektors zur Reduktion von Treibhausgasemissionen wird der Frage nachgegangen, inwiefern städtische Rahmenbedingungen die Adoption von Elektrofahrzeugen beeinflussen. Ziel der Untersuchung ist es, mittels des k-Means++-Clustering-Algorithmus strukturelle Muster innerhalb von 77 deutschen Großstädten und Landeshauptstädten zu identifizieren.

Als zentrale Analysevariablen dienen der Anteil von Elektrofahrzeugen am Pkw-Bestand, die Dichte öffentlicher Ladepunkte, das Primäreinkommen sowie die Bevölkerungsdichte. Die durchgeführte Clusteranalyse führt zur Identifikation von vier distinkten Stadttypen, die ein Spektrum von strukturschwachen Städten mit geringer Elektromobilitätsdurchdringung bis hin zu wohlhabenden Metropolen sowie spezialisierten Automobilstandorten abbilden. Die Ergebnisse zeigen einen signifikanten Zusammenhang zwischen wirtschaftlicher Leistungsfähigkeit und der Verbreitung von Elektromobilität.

Zudem wird deutlich, dass die Ladeinfrastruktur weniger als alleiniger Treiber der Nachfrage wirkt, sondern vielmehr als notwendige Voraussetzung im Sinne eines “Hygienefaktors“ zu verstehen ist, dessen unzureichende Ausprägung die Adoption von Elektrofahrzeugen hemmt. Insgesamt leistet die Arbeit einen Beitrag zur differenzierten Analyse des deutschen Elektromobilitätsmarktes, schließt eine bestehende Forschungslücke und bietet zugleich eine methodische Grundlage für eine zielgerichtete Planung und den Ausbau urbaner Ladeinfrastruktur.

I. EINLEITUNG

Themen wie Klimawandel, Treibhausgase und Klimaschutz sind im aktuellen Zeitalter nicht mehr ausschließlich als Nischenthemen zu betrachten. Insbesondere im europäischen Kontext verursacht der persönliche Transport einen erheblichen Anteil der Gesamtemissionen [1]. Dies hat in den vergangenen Jahren im deutschen Automobilmarkt dazu geführt, dass die Antriebswende zunehmend den Fokus von fossilen Energieträgern hin zu elektrischen Alternativen verschiebt.

Zur Umsetzung dieser Ziele wurden im Koalitionsvertrag verschiedene Maßnahmen festgelegt, darunter insbesondere die Förderung von Elektrofahrzeugen sowie der Ausbau der hierfür notwendigen Ladeinfrastruktur [2]. Vor diesem Hintergrund stellt sich zunehmend die Frage, an welchen Standorten der Ausbau der Ladeinfrastruktur am dringendsten erforderlich ist, um den Betrieb emissionsarmer Fahrzeuge im Alltag zuverlässig zu ermöglichen. Dabei ist insbesondere relevant, wo ein hoher Anteil an Elektrofahrzeugen bereits vorhanden ist oder sich zukünftig entwickeln kann. Um

jedoch zu verstehen, welche Faktoren diesen Anteil beeinflussen, werden in der vorliegenden Arbeit ausgewählte Einflussgrößen betrachtet. Da Elektrofahrzeuge im Vergleich zu konventionellen Verbrennerfahrzeugen noch relativ neu am Markt sind, sind sie häufig mit höheren Anschaffungskosten verbunden. Daher stellt das Wohlstandsniveau bzw. das Einkommen einer Stadt einen wesentlichen Einflussfaktor dar.

Zudem kann die Kaufbereitschaft durch eine unzureichende oder nicht flächendeckend verfügbare öffentliche Ladeinfrastruktur negativ beeinflusst werden, da hierdurch Unsicherheiten hinsichtlich der Reichweite entstehen. Dieses Spannungsfeld wird in der Literatur häufig als Henne-Ei-Problem beschrieben [3, 4].

Um einen repräsentativen Überblick über die Situation in Deutschland zu ermöglichen, konzentriert sich diese Arbeit auf deutsche Groß- und Landeshauptstädte. Zur Untersuchung möglicher Zusammenhänge zwischen den genannten Einflussfaktoren und dem Anteil von Elektrofahrzeugen in einer Stadt wird ein Clustering-Algorithmus eingesetzt. Das K-Means-Clustering ist ein iterativer, zentroidbasierter Algorithmus des unüberwachten Lernens, der Datenpunkte durch Minimierung der quadrierten euklidischen Abstände den jeweils nächstgelegenen Clusterzentren zuordnet. Da die Qualität der Ergebnisse stark von der initialen Positionierung dieser Zentren abhängt, optimiert das K-Means++-Verfahren nach Arthur und Vassilvitskii den Initialisierungsprozess durch eine probabilistische Strategie, bei der neue Zentren mit einer Wahrscheinlichkeit proportional zu ihrem quadrierten Abstand zu bereits gewählten Zentren ausgewählt werden. Dadurch werden die Zentren gezielt möglichst weit voneinander entfernt platziert, wodurch das Risiko ungünstiger lokaler Minima reduziert und die Stabilität sowie Reproduzierbarkeit der Clusterzuordnung verbessert werden [5].

Die vorliegende Arbeit ist wie folgt aufgebaut: Abschnitt II gibt einen Überblick über den aktuellen Stand der Forschung und identifiziert bestehende Forschungslücken. Abschnitt III beschreibt das methodische Vorgehen des eingesetzten Clustering-Algorithmus. Die Ergebnisse der Untersuchung werden in Abschnitt IV präsentiert und anschließend in Abschnitt V diskutiert. Abschließend fasst Abschnitt VI die wesentlichen Erkenntnisse der Arbeit zusammen und gibt einen Ausblick auf mögliche zukünftige Forschungsansätze.

*This work was not supported by any organization

II. LITERATUR

1) *EV-Adoption und Einflussfaktoren:* [4] führt eine Umfrage in nordeuropäischen EU-Ländern durch, um zu untersuchen, welche Faktoren die Befragten davon abhalten, auf ein Elektrofahrzeug umzusteigen. Dabei zeigt sich, dass neben der unzureichenden Ladeinfrastruktur und den hohen Anschaffungskosten insbesondere Informationsdefizite sowie Unsicherheiten im Umgang mit neuer Technologie zentrale Hürden für die Elektromobilität darstellen. [6] ergänzt diese Ergebnisse und stellt fest, dass neben den Anschaffungskosten auch Unsicherheiten hinsichtlich des Werterhalts sowie der langfristigen Nutzung batterieelektrischer Fahrzeuge bestehen. Darüber hinaus äußerten einige Befragte Zweifel an der allgemeinen Umweltfreundlichkeit von Elektrofahrzeugen, insbesondere in Bezug auf deren Herstellung. Als zentrale Motivatoren für die Adoption werden hingegen wirtschaftliche Anreize wie Steuervorteile sowie reduzierte Betriebskosten genannt, ergänzt durch Aspekte wie Lärmreduktion und geringere Emissionen.

2) *Planung Ladeinfrastruktur:* [1] befassen sich in ihrer Studie mit der übergeordneten Planung von Ladeinfrastruktur, die sich nicht ausschließlich auf urbane Räume beschränkt. Obwohl etwa die Hälfte der befragten Elektrofahrzeugnutzer ihr Fahrzeug überwiegend oder ausschließlich an privaten Ladestationen lädt, ist die andere Hälfte auf öffentliche Ladeinfrastruktur angewiesen. In diesem Zusammenhang wird zudem auf die teilweise geringe Auslastung öffentlicher Ladesäulen hingewiesen, was auf eine unzureichende oder ineffiziente Standortplanung hindeutet. Darüber hinaus wird der Einfluss des Stromnetzes detailliert betrachtet, insbesondere im Hinblick auf die Frage, welche Lademöglichkeiten durch die bestehende Netzinfrastuktur tatsächlich unterstützt werden können.

3) *Clustering-Methoden:* [7] untersucht die Komplexität moderner Stadtstrukturen sowie deren Infrastrukturbedarfe in chinesischen Sekundärstädten. Hierfür wird die TOPSIS-Methode (Technique for Order of Preference by Similarity to Ideal Solution) eingesetzt, um unterschiedliche Stadteigenschaften in mehreren Dimensionen mathematisch zu bewerten und einzuordnen. Im Vergleich zu einer rein quantitativen Sortierung ermöglicht dieser Ansatz eine höhere Genauigkeit sowie eine feinere Differenzierung zwischen den betrachteten Einheiten. Die anschließende K-Means-Clusteranalyse dient in der Studie als methodische Grundlage, da Städte mit unterschiedlichen Merkmalsausprägungen ebenfalls in Gruppen ähnlicher Eigenschaften eingeordnet werden sollen. Durch die Kombination städtischer Charakteristika mit Elektromobilitätsdaten können Städte nicht nur hinsichtlich ihres Status quo bewertet, sondern auch in funktional ähnliche Cluster unterteilt werden. Aufgrund des hohen methodischen Aufwands der TOPSIS-Analyse wurde in der Studie jedoch primär auf vorbereitete Datengrundlagen sowie die anschließende Clusteranalyse zurückgegriffen. Abschließend zeigt [7], dass Kernstädte zwar häufig in Bezug auf Innovation und wirtschaftliche Größe dominieren, Sekundärstädte bzw. Randregionen je-

doch teilweise bessere Werte hinsichtlich Umweltqualität und Energieeffizienz aufweisen können. Dies deutet darauf hin, dass eine hohe städtische Zentralität nicht zwangsläufig mit einer überlegenen ökologischen Infrastruktur einhergeht. [8] untersucht die räumliche Planung öffentlicher Ladeinfrastruktur in dicht besiedelten urbanen Räumen kritisch am Beispiel Hongkongs, da dort aufgrund der hohen Bevölkerungsdichte keine weitreichende private Ladeinfrastruktur realisierbar ist. Dabei wird insbesondere der ortsbezogene Zusammenhang zwischen Infrastrukturangebot und Nachfrage betrachtet. Dies stützt die in der vorliegenden Arbeit verwendeten Stadtstrukturindikatoren (z. B. Dichte und Landnutzung) sowie sozioökonomische Variablen (z. B. Einkommen). Diese sind nach [8] eng mit der tatsächlichen Nachfrage nach Elektrofahrzeugen sowie der Effektivität der Infrastrukturversorgung verknüpft. [9] verwendet ebenfalls einen K-Means-Algorithmus zur Untersuchung von Elektromobilität sowie der Einflüsse der Ladeinfrastruktur. Diese Methode wird als skalierbar und flexibel im Kontext der Verarbeitung stadtbezogener Daten beschrieben. Mithilfe von Validierungsmetriken wie dem Silhouette-Koeffizienten und dem Davies-Bouldin-Index ist es möglich, die Ergebnisse des Clusterings vergleichbar zu machen und essenzielle Muster für die Infrastrukturplanung zu identifizieren.

4) *Forschungslücke und Forschungsfrage:* Die bestehende Forschung zur Verbreitung von Elektrofahrzeugen sowie zur Rolle städtischer Rahmenbedingungen konzentriert sich bislang überwiegend auf internationale oder nicht-deutsche Kontexte. Eine spezifische Betrachtung deutscher Großstädte und ihrer strukturellen Unterschiede ist hingegen nur unzureichend vorhanden. Dies stellt eine relevante Forschungslücke dar, da sich urbane Strukturen, Mobilitätsverhalten und politische Rahmenbedingungen länderspezifisch deutlich unterscheiden können und somit eine Übertragbarkeit bestehender Erkenntnisse nicht ohne Weiteres gegeben ist. Darüber hinaus zeigt die Literatur, dass Ladeinfrastruktur zwar häufig als zentrales Hindernis für die Verbreitung von Elektrofahrzeugen genannt wird, ihre tatsächliche Rolle jedoch differenzierter zu betrachten ist. Insbesondere wird argumentiert, dass eine gut ausgebaute Ladeinfrastruktur weniger als aktiver Motivationsfaktor wirkt, sondern vielmehr als sogenannter "Hygienefaktor" zu verstehen ist: Ihr Fehlen kann die Adoption von Elektrofahrzeugen hemmen, während ihr Vorhandensein allein nicht zwangsläufig zu einer erhöhten Nachfrage führt [8]. Diese ambivalente Rolle der Infrastruktur ist bislang nicht hinreichend im Kontext systematischer Stadtvergleiche untersucht worden.

Vor diesem Hintergrund ergibt sich die zentrale Forschungsfrage der vorliegenden Arbeit:

Inwiefern lassen sich deutsche Großstädte anhand ihrer städtischen Charakteristika, des Elektrofahrzeuganteils sowie der Ladeinfrastruktur mithilfe von Clustering-Algorithmen klassifizieren?

III. METHODIK

A. Untersuchungsmenge

Die Analyse umfasst $n = 77$ deutsche Großstädte. Die Untersuchungsmenge setzt sich aus allen Städten mit mindestens 100.000 Einwohnern sowie allen 16 Landeshauptstädten zusammen. Eine Ausnahme bildet hierbei Schwerin, das trotz Unterschreitens der 100.000-Einwohner-Schwelle in die Stichprobe aufgenommen wurde. Jede Stadt wird über ihren achtstelligen Amtlichen Gemeindegeschlüssel (AGS) eindeutig identifiziert. Dieser dient zugleich als Verknüpfungsschlüssel über alle verwendeten Datenquellen hinweg.

B. Datenquellen

Für jede Stadt wurden vier zentrale Merkmale aus unterschiedlichen Themenfeldern erhoben:

Merkmal	Quelle	Bezugsgröße
Pkw-Elektro-Anteil	[10]	Elektromobilität
Ladepunkte je 1.000 Einwohner	[11]	Infrastruktur
Primäreinkommen je Einwohner (EUR)	[12]	Einkommen
Einwohner je Stadt	[13]	Bevölkerung

TABLE I: Übersicht der verwendeten Merkmale und Datenquellen

Der Anteil der Elektroautos pro Stadt wurde gewählt um einen den aktuellen Stand der Elektromobilität in den jeweiligen Städten zu ermitteln. Die aktuellen Zulassungszahlen werden regelmäßig vom Kraftfahrtbundesamt veröffentlicht [10]. Da das Ladesäulenregister lediglich absolute Ladepunktzahlen [11] für jede Stadt ausweist, wurden diese zur besseren Vergleichbarkeit mit Hilfe der Bevölkerungszahlen [14] auf je 1000 Einwohner berechnet, um eine einheitliche Pro-Kopf-Kennzahl zu erhalten. Das Primäreinkommen je Einwohner wurde gewählt da der Faktor Anschaffungswert in vielen Vorstudien als sehr wichtig eingestuft wurde [13]. Somit kann festgestellt werden ob das durchschnittliche Einkommen einen Einfluss auf die Erschwinglichkeit von Elektrofahrzeugen nimmt. Hierbei wurde nicht auf die Kaufkraft geachtet, was die unterschiedlichen Lebenskosten der Städte außen vor lässt.

Das Projekt ist mit allen Dateien und Ergebnissen in einem öffentlichen Github Repository hinterlegt [15]. Das Repository ist in *data*, *output*, *source* und weitere Dateien aufgeteilt. Unter *data/raw* sind alle originalen Datenquellen gespeichert mit dem aktuellen Stand der Arbeit. *data/processed* enthält die bereinigten Daten, welche für die zusammengefügte master datei unter *data/master* verwendet werden. *src* enthält den code für die Clusteringanalyse. *data_clean.ipynb* ist für die bereinigung der Datenquellen zuständig. *03_merge.py* ist für die Erstellung der master datei zuständig. *04_cluster.py* ist der Kern dieser Arbeit und übernimmt die Logic für den Cluster-Algorithmus. Die Ergebnisse werden in *output* hinterlegt. Alle Clusters sind unter *figures* als .png Datei und unter *tables* als .csv gespeichert. Eine weitere wichtige Datei ist die *requirements.txt* für das ausführen der Python Skripte.

C. Datenaufbereitung und -zusammenführung

Die in der Analyse verwendeten Einzeldatensätze liegen in unterschiedlichen regionalen Schlüsselssystemen und räumlichen Referenzebenen wie Postleitzahl, Gemeindegeschlüssel oder Stadtnamen vor, was eine unmittelbare Verknüpfung zunächst erschwert. Um eine konsistente und vergleichbare Datenbasis zu gewährleisten, wurden sämtliche Datensätze bei der Zusammenführung auf den einheitlichen achtstelligen Amtlichen Gemeindegeschlüssel (AGS) standardisiert. Dadurch wird sichergestellt, dass alle betrachteten Variablen eindeutig den entsprechenden Städten zugeordnet werden können und eine fehlerfreie Integration der Daten erfolgt:

- **EV-Anteil:** Der Gemeindegeschlüssel (AGS) wurde normalisiert und um fehlende führende Nullen ergänzt. Aus der verfügbaren vierteljährlichen Zeitreihe wurde der aktuellste Stand (2026.04) extrahiert.
- **Einwohnerdaten:** Der ursprünglich zwölfstellige Regionalschlüssel wurde auf den achtstelligen AGS reduziert.
- **Primäreinkommen:** Die Daten liegen auf Kreisebene (fünfstelliger Schlüssel) vor und wurden über die ersten fünf Stellen des AGS zugeordnet. Für die Stadtstaaten Berlin und Hamburg erfolgte die Zuordnung auf Länderebene.
- **Ladepunkte:** Das Ladesäulenregister enthält keinen AGS, sondern lediglich Postleitzahlen und Ortsnamen. Die Zuordnung erfolgte über exakte Ortsnamenabgleiche sowie eindeutige Schreibweisen von Stadtteilen. Abweichende Klammerzusätze wurden ausgeschlossen, um Fehlzuordnungen gleichnamiger Orte zu vermeiden.

Die Merkmalswerte wurden robust geparkt und hinsichtlich deutscher sowie englischer Zahlenformate vereinheitlicht. Nach der Zusammenführung lagen für alle 77 Städte vollständige Datensätze ohne fehlende Werte vor. Das Ergebnis bildet eine konsolidierte Mastertabelle mit einer Zeile pro Stadt.

D. Standardisierung

Da die vier betrachteten Merkmale unterschiedliche Skalen und Einheiten aufweisen – darunter Prozentwerte (z. B. EV-Anteile), monetäre Größen (Primäreinkommen in Euro), absolute Zählwerte (Bevölkerungsdichte) sowie infrastrukturelle Kennzahlen – ist eine direkte Vergleichbarkeit der Variablen ohne vorherige Transformation nicht gegeben. Da der k-Means-Algorithmus auf der Berechnung euklidischer Distanzen im Merkmalsraum basiert, würden Variablen mit größeren Wertebereichen andernfalls einen überproportional starken Einfluss auf die Clusterbildung ausüben. Um diese Verzerrung zu vermeiden, wurden alle Variablen vor der Clusteranalyse mittels Z-Transformation standardisiert. Dabei werden die Merkmale so transformiert, dass sie jeweils einen Mittelwert von 0 und eine Standardabweichung von 1 aufweisen. Auf diese Weise tragen alle Variablen unabhängig von ihrer ursprünglichen Skala gleichgewichtet zur Distanzberechnung bei, wodurch insbeson-

dere eine Dominanz des Einkommensmerkmals innerhalb der Clusterbildung verhindert wird.

E. Clusteranalyse

Für die Clusterbildung wurde der **k-Means++**-Algorithmus eingesetzt, der gegenüber dem klassischen k-Means eine verbesserte Initialisierung der Clusterzentren aufweist. Zur Erhöhung der Stabilität wurde der Algorithmus für jede getestete Clusteranzahl zehnmal mit unterschiedlichen Initialisierungen ausgeführt (`n_init = 10`). Als finale Lösung wurde jeweils die Variante mit der geringsten Inertia ausgewählt. Ein fester Zufallswert (`random_state = 42`) gewährleistet die Reproduzierbarkeit der Ergebnisse.

Die Bestimmung der optimalen Clusteranzahl k erfolgte mithilfe einer kombinierten Elbow- und Silhouettenanalyse für Werte von $k = 2$ bis $k = 8$ (siehe Ergebnisteil). Auf Basis dieser Analyse wurde $k = 4$ gewählt.

Zur Visualisierung der vierdimensionalen Datenstruktur wurde eine Hauptkomponentenanalyse (PCA) durchgeführt, wobei die Daten auf zwei Dimensionen reduziert wurden. Die ersten beiden Hauptkomponenten erklären dabei rund 83 % der Gesamtvarianz.

F. Software

Die Umsetzung der Analyse erfolgte in Python unter Verwendung der Bibliotheken *pandas* für das Datenhandling, *scikit-learn* (StandardScaler, KMeans, PCA, *silhouette_score*) sowie *matplotlib* zur Visualisierung. Die vollständige Datenpipeline ist in den Skripten `src/03_merge.py` und `src/04_cluster.py` dokumentiert und vollständig reproduzierbar. Zudem wurden AI Tools wie Claude Code für die Erstellung des Clustering-Algorithmus Skripten genutzt.

IV. DISKUSSION

V. ERGEBNISSE — CLUSTERANALYSE

Der folgende Abschnitt fasst die Ergebnisse der Clusteranalyse zusammen und diskutiert deren Einordnung im Kontext der untersuchten städtischen Charakteristika, der Elektromobilität sowie der Ladeinfrastruktur. Die zugrunde liegenden Kennzahlen stammen aus `output/tables/cluster_profile.csv` (Stand: aktueller Lauf, $k = 4$). Es ist zu beachten, dass die Cluster-Nummerierung keine inhärente Reihenfolge besitzt und sich bei erneuten Modellläufen verändern kann.

A. Bestimmung der Clusterzahl

Zur Festlegung der geeigneten Clusteranzahl wurden für $k = 2$ bis $k = 8$ sowohl die Within-Cluster-Sum-of-Squares (Inertia, Elbow-Methode) als auch der mittlere Silhouettenkoeffizient berechnet. Dargestellt in Abbildung 1 und 2. Der Silhouettenkoeffizient erreicht sein Maximum bei $k = 2$ (0,44), was darauf hinweist, dass in diesem Fall primär eine grobe Trennung zwischen einer besonders wohlhabenden, EV-affinen Gruppe und den übrigen Städten erfolgt.




Fig. 1: Elbow Methode zur Bestimmung der Clusteranzahl




Fig. 2: Silhouette Analyse zur Bestimmung der Clusteranzahl

Da diese Zweiteilung jedoch für eine differenzierte Typisierung deutscher Großstädte zu wenig granular ist, wurde die Clusterlösung dennoch weiter differenziert betrachtet. Die Inertia-Kurve zeigt bei $k = 4$ einen deutlichen Knick, so dass diese Clusteranzahl als sinnvoller Kompromiss zwischen statistischer Güte und inhaltlicher Interpretierbarkeit gewählt wurde.

B. Beschreibung der vier Cluster

Die k-Means++-Clusteranalyse (standardisierte Merkmale, $n = 77$ Großstädte) ergibt vier klar unterscheidbare Stadttypen. Tabelle II zeigt die jeweiligen Mittelwerte der Merkmale je Cluster, während Abbildung 3 die Verteilungen der einzelnen Variablen visualisiert.

Anzahl Städte	EV-Anteil (%)	Ladepunkte je 1.000 EW	Einkommen (EUR)	Bev.-Dichte (EW/km ²)
29	5,59	1,96	27.895,68	1.460,79
11	10,24	4,63	43.829,76	2.291,00
35	7,78	2,55	34.351,36	1.910,06
2	17,90	9,33	37.051,79	846,00

TABLE II: Profilierung der Cluster




Fig. 3: Cluster Verteilung

a) Cluster 0 — Strukturschwächere Städte (n = 29).:

Dieser Cluster weist insgesamt die niedrigsten Ausprägungen in den betrachteten Variablen auf. Dazu zählen ein geringer EV-Anteil ($\bar{x}$ 5,6 %), eine niedrige Ladepunktdichte ($\bar{x}$ 2,0 je 1.000 Einwohner) sowie das niedrigste durchschnittliche Primäreinkommen ($\bar{x}$ 27.896 €). Räumlich konzentrieren sich die Städte dieses Clusters vor allem auf zwei historisch und strukturell verwandte Regionen: zum einen altindustriell geprägte Städte des Ruhrgebiets (z.,B. Duisburg, Gelsenkirchen, Oberhausen, Herne) und zum anderen mehrere ostdeutsche Großstädte (u.,a. Chemnitz, Halle, Magdeburg, Rostock). Die Gemeinsamkeiten dieser Regionen lassen sich auf langfristige strukturelle Transformationsprozesse zurückführen, die sowohl das Ruhrgebiet als auch Teile Ostdeutschlands prägen. Diese gehen mit einem vergleichsweise niedrigen Einkommensniveau und einer geringeren wirtschaftlichen Dynamik einher, was die Kaufkraft der Haushalte reduziert und damit die Anschaffung von Elektrofahrzeugen erschwert. Zusätzlich bestehen infrastrukturelle und bauliche Hemmnisse, wobei wenig Ladeplätze pro Person zur Verfügung stehen da eine hohe Bevölkerungsdichte herrscht. In Kombination mit einer vergleichsweise schwach ausgebauten öffentlichen Ladeinfrastruktur entsteht dadurch eine doppelte Barriere, die sowohl die Nachfrage- als auch die Nutzungsseite der Elektromobilität betrifft.

Insgesamt zeigt sich, dass die geringe Verbreitung von Elektromobilität in diesen Regionen nicht monokausal erklärbar ist, sondern aus dem Zusammenspiel sozioökonomischer und infrastruktureller Restriktionen resultiert.

b) Cluster 1 — Wohlhabende Metropolen (n = 11).:

Dieser Cluster umfasst die einkommensstärksten Städte der Analyse und zeichnet sich durch ein durchschnittliches Primäreinkommen von 43.830 € aus. Gleichzeitig weist er mit 10,2% den höchsten mittleren Anteil an Elektrofahrzeugen sowie mit 4,6 Ladepunkten je 1.000 Einwohner eine vergleichsweise gut ausgebauten Ladeinfrastruktur auf.

Ergänzend zeigt sich in diesem Cluster die höchste durchschnittliche Bevölkerungsdichte mit 2.291 Einwohnern pro km², was auf eine besonders stark verdichtete urbane Struktur hinweist. Zu den typischen Vertretern dieses Clusters zählen unter anderem München, Frankfurt am Main, Stuttgart, Düsseldorf und Heidelberg. Diese Städte weisen insgesamt konsistent hohe Ausprägungen sowohl in den sozioökonomischen als auch in den infrastrukturellen Variablen auf und unterscheiden sich damit deutlich von den übrigen Clustern. Das beobachtete Muster deutet auf einen positiven Zusammenhang zwischen wirtschaftlicher Leistungsfähigkeit und der Adoption von Elektromobilität hin, da sowohl die Ausstattung mit Ladeinfrastruktur als auch die Verbreitung von Elektrofahrzeugen in diesen wohlhabenden und dicht besiedelten Metropolen besonders stark ausgeprägt sind.

c) Cluster 2 — Durchschnittliche Großstädte (n = 35).:

Der größte Cluster bildet ein breites Mittelfeld der deutschen Großstädte ab. Der EV-Anteil liegt hier im Durchschnitt bei 7,8 %, das Einkommen bei 34.351 € und die Ladepunktdichte bei 2,6 je 1.000 Einwohner. Zu diesem Cluster zählen unter anderem große deutsche Metropolen wie Berlin, Hamburg, Köln und Nürnberg, aber auch eine Vielzahl weiterer Städte ohne stark ausgeprägte strukturelle Besonderheiten in den betrachteten Merkmalen. Insgesamt liegen die Kennzahlen dieses Clusters nahe am Gesamtdurchschnitt aller untersuchten Städte, sowohl hinsichtlich der wirtschaftlichen als auch der infrastrukturellen Variablen.

Vor diesem Hintergrund kann dieser Cluster als repräsentative "typische Großstadtstruktur" interpretiert werden, die weder besonders hohe noch besonders niedrige Ausprägungen in den untersuchten Dimensionen aufweist und somit den zentralen Referenzbereich der Analyse darstellt.

d) Cluster 3 — Automobil-Hochburgen (n = 2).: Ingolstadt und Wolfsburg bilden einen stark abgegrenzten Sondercluster mit einem außergewöhnlich hohen EV-Anteil ($\bar{x}$ 17,9%) sowie einer überdurchschnittlich hohen Ladepunktdichte ($\bar{x}$ 9,3 je 1.000 Einwohner). Gleichzeitig weisen diese Städte die niedrigste Bevölkerungsdichte ($\bar{x}$ 846 Einwohner/km²) auf. Beide Städte sind durch die Präsenz großer Automobilhersteller (Audi bzw. Volkswagen) geprägt, sodass der hohe EV-Anteil teilweise auf unternehmensnahe Fahrzeugflotten und Mitarbeiterfahrzeuge zurückgeführt werden kann.

C. Einordnung

Die Darstellung in der Hauptkomponentenanalyse in Abbildung 4 bestätigt die zuvor identifizierten Clusterstrukturen und verdeutlicht zugleich deren Einordnung in einen übergeordneten kontinuierlichen Merkmalsraum. Durch die Dimensionsreduktion der vier betrachteten Variablen auf zwei Hauptkomponenten, die gemeinsam 83, % der Gesamtvarianz erklären, wird insbesondere die erste Hauptkomponente mit 55, % erklärter Varianz als zentraler Strukturgradient sichtbar. Diese Achse lässt sich als Ausdruck einer sozioökonomischen "EV-Reife" interpretieren, entlang




Fig. 4: Zuordnung der Großstädte

derer sich insbesondere die Cluster 0, 1 und 2 anordnen. Dabei steigt entlang dieses Gradienten insbesondere das Primäreinkommen deutlich an und korreliert gleichzeitig mit einer zunehmenden Ausprägung der Elektromobilität. Cluster 3 stellt hingegen einen klar separierten Sonderfall dar.

Insgesamt wird deutlich, dass Elektromobilität in den betrachteten Städten eng an die wirtschaftliche Leistungsfähigkeit gekoppelt ist und sich nicht unabhängig davon entwickelt. Städte im mittleren Bereich (Cluster 2) bewegen sich dabei innerhalb eines Übergangsraums zwischen strukturschwachen und wohlhabenden Metropolen und verfügen zwar über eine solide Ausgangsbasis, haben jedoch das Niveau der stark ausgeprägten Cluster 1 Strukturen noch nicht erreicht.

Gleichzeitig zeigen die Ergebnisse, dass die Cluster nicht als strikt getrennte Kategorien zu interpretieren sind. Der vergleichsweise niedrige Silhouettenkoeffizient von 0,24 bei $k = 4$ deutet auf fließende Übergänge zwischen den Gruppen hin, insbesondere zwischen dem durchschnittlichen Cluster 2 und dem strukturschwachen Cluster 0. Die identifizierten Stadttypen sind daher eher als idealtypische Positionen innerhalb eines kontinuierlichen Merkmalsraums zu verstehen, in dem viele Städte hybride Eigenschaften mehrerer Cluster aufweisen.

Einschränkend ist zudem die geringe Größe von Cluster 3 ($n = 2$) zu berücksichtigen, die die statistische Verallgemeinerbarkeit dieses Sonderfalls begrenzt. Darüber hinaus lässt sich kritisch anmerken, dass die Clusterbildung ausschließlich auf vier Variablen basiert und damit nur einen Ausschnitt der komplexen urbanen Mobilitätsrealität abbildet. Zusätzliche Faktoren wie etwa die Qualität des öffentlichen Personennahverkehrs oder der Anteil von Eigenheimstrukturen könnten die Differenzierung weiter schärfen, standen jedoch im Rahmen dieser Untersuchung nicht für alle Städte konsistent zur Verfügung.

VI. CONCLUSIONS

Zusammenfassend zeigt die vorliegende Arbeit, dass eine Klassifikation deutscher Großstädte auf Basis von Ur-

banitäts- und Elektromobilitätsmerkmalen mithilfe des k-Means++-Algorithmus erfolgreich möglich ist. Durch die Analyse von 77 Städten konnten vier charakteristische Stadttypen identifiziert werden, die die strukturellen Unterschiede im deutschen Stadtsystem deutlich machen und somit einen Beitrag zur Schließung einer bestehenden Forschungslücke leisten.

Die Ergebnisse verdeutlichen insbesondere einen signifikanten Zusammenhang zwischen der wirtschaftlichen Leistungsfähigkeit einer Stadt und der Verbreitung von Elektromobilität. Wohlhabende Metropolen weisen sowohl eine hohe Dichte an Elektrofahrzeugen als auch eine gut ausgebaute Ladeinfrastruktur auf, während strukturschwächere Städte – insbesondere im Ruhrgebiet und in Teilen Ostdeutschlands – in allen betrachteten Dimensionen geringere Ausprägungen zeigen. Dies unterstreicht die zentrale Bedeutung der Kaufkraft als entscheidenden Einflussfaktor für die Adoption von Elektrofahrzeugen. Gleichzeitig konnten mit den sogenannten “Automobil-Hochburgen” spezifische Sonderfälle identifiziert werden, deren überdurchschnittlich hohe Elektrofahrzeuganteile maßgeblich durch unternehmensnahe Flottenstrukturen geprägt sind.

Darüber hinaus legen die Ergebnisse nahe, dass die Ladeinfrastruktur als notwendige, jedoch nicht hinreichende Bedingung für die Verbreitung von Elektromobilität zu verstehen ist. Sie fungiert somit als Hygienefaktor, dessen Ausbau zwar essenziell für den Abbau von Nutzungsbarrieren ist, jedoch ohne entsprechende ökonomische Rahmenbedingungen keine ausreichende Nachfrage generiert. Ergänzend zeigt die Hauptkomponentenanalyse, dass die Übergänge zwischen den Städten überwiegend fließend sind und die identifizierten Cluster eher als Positionen innerhalb eines kontinuierlichen Merkmalsraums denn als strikt abgegrenzte Kategorien interpretiert werden sollten.

Abschließend eröffnet die Arbeit mehrere Ansatzpunkte für weiterführende Forschung. Insbesondere erscheint die Untersuchung zeitlicher Entwicklungen der identifizierten Cluster vielversprechend, um die Dynamik der Transformation hin zu nachhaltigen Mobilitätssystemen besser zu verstehen. Darüber hinaus könnte die Integration zusätzlicher Einflussfaktoren – wie etwa lokaler Förderprogramme, der Verfügbarkeit von Ökostrom oder der Qualität des öffentlichen Nahverkehrs – zu einer weiteren Präzisierung der Analyse beitragen. Auf dieser Grundlage lassen sich künftig noch differenziertere und zielgerichtete Handlungsempfehlungen für die strategische Planung und den bedarfsgerechten Ausbau von Ladeinfrastruktur ableiten.

REFERENCES

- [1] Tim Unterluggauer et al. “Electric vehicle charging infrastructure planning for integrated transportation and power distribution networks: A review”. In: *eTransportation* 12 (2022), p. 100163. ISSN: 2590-1168. DOI: <https://doi.org/10.1016/j.etrans.2022.100163>. URL: <https://www.sciencedirect.com/science/article/pii/S2590116822000091>.

- [2] CSU CDU and SPD. *Verantwortung für Deutschland – Koalitionsvertrag zwischen CDU, CSU und SPD*. Koalitionsvertrag. Abgerufen am 31. Mai 2026. Christlich Demokratische Union Deutschlands (CDU), Christlich-Soziale Union in Bayern (CSU), Sozialdemokratische Partei Deutschlands (SPD), Apr. 2025. URL: <https://www.cdu.de/app/uploads/2025/04/Koalitionsvertrag-%E2%80%93-barrierefreie-Version.pdf>.
- [3] Lefeng Shi et al. “A comprehensive charging network planning scheme for promoting EV charging infrastructure considering the Chicken-Eggs dilemma”. In: *Research in Transportation Economics* 88 (2021). Transport Infrastructures: Investments, Evaluation and Regional Economic Growth, p. 100837. ISSN: 0739-8859. DOI: <https://doi.org/10.1016/j.retrec.2020.100837>. URL: <https://www.sciencedirect.com/science/article/pii/S0739885920300263>.
- [4] Lance Noel et al. “Understanding the socio-technical nexus of Nordic electric vehicle (EV) barriers: A qualitative discussion of range, price, charging and knowledge”. In: *Energy Policy* 138 (2020), p. 111292. ISSN: 0301-4215. DOI: <https://doi.org/10.1016/j.enpol.2020.111292>. URL: <https://www.sciencedirect.com/science/article/pii/S0301421520300501>.
- [5] David Arthur and Sergei Vassilvitskii. “k-means++: The Advantages of Careful Seeding”. In: *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*. SODA '07. Philadelphia, PA, USA: Society for Industrial and Applied Mathematics, 2007, pp. 1027–1035.
- [6] Mehmet Efe Biresselioglu, Melike Demirbag Kaplan, and Barbara Katharina Yilmaz. “Electric mobility in Europe: A comprehensive review of motivators and barriers in decision making processes”. In: *Transportation Research Part A: Policy and Practice* 109 (2018), pp. 1–13. ISSN: 0965-8564. DOI: <https://doi.org/10.1016/j.tra.2018.01.017>. URL: <https://www.sciencedirect.com/science/article/pii/S0965856417311771>.
- [7] Yizhao Du, Rodrigo V. Cardoso, and Roberto Rocco. “The challenges of high-quality development in Chinese secondary cities: A typological exploration”. In: *Sustainable Cities and Society* 103 (2024), p. 105266. ISSN: 2210-6707. DOI: <https://doi.org/10.1016/j.scs.2024.105266>. URL: <https://www.sciencedirect.com/science/article/pii/S2210670724000957>.
- [8] Sylvia Y. He, Yong-Hong Kuo, and Ka Kit Sun. “The spatial planning of public electric vehicle charging infrastructure in a high-density city using a contextualised location-allocation model”. In: *Transportation Research Part A: Policy and Practice* 160 (2022), pp. 21–44. ISSN: 0965-8564. DOI: <https://doi.org/10.1016/j.tra.2022.02.012>. URL: <https://www.sciencedirect.com/science/article/pii/S0965856422000465>.
- [9] Marcelo Forte et al. “A comprehensive review of clustering methods applications in electric mobility”. In: *Transportation Engineering* 21 (2025), p. 100360. ISSN: 2666-691X. DOI: <https://doi.org/10.1016/j.treng.2025.100360>. URL: <https://www.sciencedirect.com/science/article/pii/S2666691X25000594>.
- [10] Kraftfahrt-Bundesamt (KBA). *Statistikportal: FZ Pkw mit Elektroantrieb (Gemeinde)*. Online im KBA-Statistikportal (ArcGIS Hub). Abgerufen am 25. Mai 2026. 2026. URL: <https://das-kba-statistikportal.hub.arcgis.com/datasets/statistikportal:fz-pkw-mit-elektroantrieb-gemeinde/about>.
- [11] Bundesnetzagentur (BNetzA). *Ladesäulenregister (Stand: 22.04.2026)*. Online im Open-Data-Portal der Bundesnetzagentur. Datenstand: 22. April 2026, Abgerufen am

25. Mai 2026. 2026. URL: https://data.bundesnetzagentur.de/Bundesnetzagentur/DE/Fachthemen/ElektrizitaetundGas/E-Mobilitaet/Ladesaeulenregister_BNetzA_2026-04-22.csv.
- [12] Arbeitskreis Volkswirtschaftliche Gesamtrechnungen der Länder (AK VGRdl). *Volkswirtschaftliche Gesamtrechnungen der Länder (VGRdl) – Berechnungsstand 2024, Revision 2024 (Reihe 2, Band 3)*. Online im Statistikportal von Bund und Ländern. Veröffentlicht im Januar 2026, Abgerufen am 25. Mai 2026. 2026. URL: https://www.statistikportal.de/sites/default/files/2026-01/vgrdl_r2b3_bs2024_1.xlsx.
- [13] Statistisches Bundesamt (Destatis). *Gemeindeverzeichnis: Administrative Kreise*. Online im Datenangebot des Statistischen Bundesamtes. Abgerufen am 25. Mai 2026. 2026. URL: https://www.destatis.de/DE/Themen/Laender-Regionen/Regionales/Gemeindeverzeichnis/Administrativ/04-kreise.xlsx?__blob=publicationFile.
- [14] Bundesministerium für Wohnen, Stadtentwicklung und Bauwesen (BMWSB) and Bundesinstitut für Bau-, Stadt- und Raumforschung (BBSR). *Deutschlandatlas – Datensatz*. Online im Deutschlandatlas. Abgerufen am 25. Mai 2026. 2026. URL: <https://www.deutschlandatlas.bund.de/SharedDocs/Downloads/DE/Deutschlandatlas-Daten.html>.
- [15] .